

Universidad del Valle de Guatemala
Facultad de Ingeniería
Departamento de Ciencias de la Computación

Laboratorio 5

Clasificación de tweets usando minería de texto

CC3084 – Data Science
Semestre II – 2026

Informe final

30 de agosto de 2026

Índice

1. Introducción	2
2. Descripción del conjunto de datos	2
3. Limpieza y preprocesamiento	3
4. Frecuencias, unigramas y contexto	4
5. Análisis exploratorio visual	6
6. Modelos de clasificación	7
7. Evaluación del modelo seleccionado	8
8. Función de clasificación de nuevos tweets	9
9. Análisis de sentimiento	10
10. Tweets con polaridad extrema	11
11. Negatividad y categoría de desastre	12
12. Efecto de incorporar la negatividad al clasificador	13
13. Reproducibilidad y productos generados	15

1. Introducción

El propósito del Laboratorio 5 es construir y evaluar un sistema capaz de determinar si un tweet se refiere a un desastre real (**target=1**) o no (**target=0**) mediante técnicas de minería de texto. Se utilizó el conjunto *Natural Language Processing with Disaster Tweets* de Kaggle, siguiendo un flujo reproducible en Python que incluye exploración, limpieza, análisis de frecuencias y n-gramas, representación TF-IDF, comparación de clasificadores, análisis de sentimiento y evaluación del efecto de incorporar una variable explícita de negatividad.

El código final se implementó en un notebook de Jupyter y conserva los archivos intermedios, figuras, métricas y modelos serializados. La selección del clasificador se efectuó con validación cruzada únicamente dentro del conjunto de entrenamiento; el conjunto de prueba se reservó para la evaluación posterior. Además, la partición se realizó agrupando por texto limpio para impedir que versiones equivalentes de un mismo tweet aparecieran simultáneamente en entrenamiento y prueba.

2. Descripción del conjunto de datos

El archivo `train.csv` contiene 7,613 observaciones y cinco variables principales: `id`, `keyword`, `location`, `text` y `target`. La variable objetivo indica si el contenido corresponde a un desastre real. La columna `keyword` presenta 61 valores nulos (0.80 %), mientras que `location` presenta 2,533 (33.27 %). Las variables `text` y `target` no presentan valores faltantes.

Cuadro 1: Valores nulos en las variables principales.

Variable	Nulos	Porcentaje
<code>keyword</code>	61	0.80 %
<code>location</code>	2,533	33.27 %
<code>text</code>	0	0.00 %
<code>target</code>	0	0.00 %

La clase 0 contiene 4,342 tweets (57.03 %) y la clase 1 contiene 3,271 (42.97 %). El desbalance es moderado, por lo que la evaluación no se basó únicamente en *accuracy*: se consideraron también precisión, *recall* y F1 macro.




Figura 1: Distribución de la variable objetivo.

Antes del modelado se identificaron 92 duplicados exactos por combinación de texto y etiqueta. Después de eliminarlos quedaron 7,521 registros; posteriormente, dos tweets quedaron vacíos tras la limpieza y fueron excluidos, por lo que el conjunto utilizado para el modelado quedó formado por 7,519 observaciones.

3. Limpieza y preprocesamiento

La función `clean_text` realiza el preprocesamiento destinado al modelo de clasificación. Las principales operaciones fueron:

- decodificación de entidades HTML y eliminación de ruido de codificación;
- conversión del texto a minúsculas;
- eliminación de URLs y menciones;
- eliminación del símbolo # conservando la palabra del hashtag;
- eliminación de emojis, signos de puntuación y números;
- conservación deliberada del token 911 por su relevancia potencial en contexto de emergencias;
- eliminación de *stopwords* en inglés, conservando las negaciones *no*, *not* y *nor*;
- normalización de espacios y eliminación de tokens no informativos de un carácter.

La eliminación de duplicados se realizó inicialmente sobre `text` y `target`. Al analizar la representación limpia se encontraron 322 textos limpios distintos repetidos, correspondientes a 1,046 filas, y 85 textos limpios asociados a etiquetas contradictorias. Por ello, la partición del conjunto se realizó con grupos definidos por `text_clean`. El resultado fue un conjunto de entrenamiento de 6,015 tweets y uno de prueba de 1,504, sin ningún texto limpio compartido entre ambos.

Cuadro 2: Ejemplos del preprocesamiento.


Texto original	Texto limpio
Our Deeds are the Reason of this #earthquake May ALLAH Forgive us all	deeds reason earthquake may allah forgive us
Forest fire near La Ronge Sask. Canada	forest fire near la ronge sask canada
13,000 people receive #wildfires evacuation orders in California	people receive wildfires evacuation orders california

4. Frecuencias, unigramas y contexto

Se calcularon unigramas, bigramas y trigramas con `CountVectorizer`. Las frecuencias muestran que en la clase de desastre real aparecen términos directamente asociados a emergencias, mientras que la clase de no desastre contiene una mayor proporción de vocabulario cotidiano y usos figurados.

Cuadro 3: Diez unigramas más frecuentes por categoría.

Desastre real		No desastre	
Palabra	Frec.	Palabra	Frec.
fire	177	like	254
news	137	not	203
via	119	new	170
disaster	116	get	163
california	114	no	151
no	112	one	133
police	108	body	116
suicide	106	would	100
people	103	via	98
killed	95	video	96



(a) Desastre real.

(b) No desastre.

Figura 2: Palabras más frecuentes después del preprocesamiento.

El análisis de bigramas evidencia la utilidad de incorporar contexto local. Expresiones como *suicide bomber*, *oil spill*, *california wildfire* y *severe thunderstorm* son mucho más específicas de un desastre real que sus palabras individuales. En la clase contraria aparecen combinaciones como *cross body*, *liked video* y *looks like*, que ilustran usos no catastróficos de vocabulario potencialmente ambiguo.

Cuadro 4: Diez bigramas más frecuentes por categoría.

Desastre real		No desastre	
Bigrama	Frec.	Bigrama	Frec.
suicide bomber	54	cross body	39
northern california	41	liked video	34
oil spill	38	full read	28
california wildfire	34	body bag	27
suicide bombing	34	body bagging	24
burning buildings	30	burning buildings	22
homes razed	29	body bags	22
latest homes	28	looks like	21
razed northern	28	reddit quarantine	21
severe thunderstorm	27	feel like	20

Los trigramas aportaron todavía más especificidad, aunque con frecuencias menores. Entre los más frecuentes de la clase de desastre se encontraron *northern california wildfire*, *homes razed northern* y *suicide bomber detonated*. Por este balance entre cobertura y contexto se utilizó TF-IDF con `ngram_range=(1,2)` en el modelado.




Figura 3: Bigramas más frecuentes en tweets de desastre real.

5. Análisis exploratorio visual

Las nubes de palabras permiten observar de forma inmediata la diferencia temática entre ambas clases. En los tweets de desastre sobresalen términos asociados a incendios, policía, víctimas y eventos de emergencia, mientras que en los tweets que no son desastre se observa vocabulario más general.




Figura 4: Nubes de palabras por categoría.

La distribución de la cantidad de palabras después de la limpieza es semejante entre clases, por lo que la longitud del tweet no aparece como un discriminante principal por sí sola. La columna **keyword**, en cambio, contiene términos que en algunos casos están fuertemente asociados a eventos

reales, aunque también conserva palabras ambiguas.




Figura 5: Exploración adicional de los datos.

6. Modelos de clasificación

Para representar el contenido textual se utilizó TF-IDF con unigramas y bigramas y un máximo de 5,000 características. El vectorizador se colocó dentro de un *Pipeline* para que su ajuste ocurriera únicamente con los datos de entrenamiento de cada partición durante la validación cruzada. Se compararon Regresión Logística, Naive Bayes Multinomial, SVM lineal y Random Forest.

La validación cruzada se realizó con `StratifiedGroupKFold` de tres particiones, preservando la proporción de clases y agrupando por texto limpio. Los resultados iniciales se muestran en la Tabla 5.

Cuadro 5: Resultados medios de validación cruzada antes del ajuste de hiperparámetros.

Modelo	Accuracy	Prec. macro	Recall macro	F1 macro
Regresion Logistica	0.7857	0.7952	0.7662	0.7720
Random Forest	0.7772	0.7825	0.7593	0.7644
Naive Bayes Multinomial	0.7799	0.7946	0.7574	0.7634
SVM lineal (LinearSVC)	0.7601	0.7559	0.7508	0.7526




Figura 6: Comparación de los modelos mediante validación cruzada.

Posteriormente se realizó **GridSearchCV** sobre los tres modelos lineales/probabilísticos con mejor potencial. La selección se basó exclusivamente en F1 macro de validación cruzada dentro del conjunto de entrenamiento.

Cuadro 6: Mejores configuraciones encontradas mediante GridSearchCV.

Modelo	F1 macro CV	Mejores parámetros
SVM lineal (LinearSVC)	0.7752	{'clf__C': 0.1, 'clf__class_weight': 'balanced'}
Regresion Logistica	0.7723	{'clf__C': 1.0, 'clf__class_weight': 'balanced'}
Naive Bayes Multinomial	0.7671	{'clf__alpha': 0.5}


El mejor resultado correspondió a SVM lineal con **C=0.1** y **class_weight='balanced'**, con F1 macro de validación cruzada igual a **0.7752**. Este modelo fue elegido antes de observar el conjunto de prueba.

7. Evaluación del modelo seleccionado


El modelo SVM seleccionado fue calibrado para obtener probabilidades y luego evaluado sobre las 1,504 observaciones reservadas para prueba. Alcanzó *accuracy* de **0.7919**, precisión macro de **0.7959**, *recall* macro de **0.7761** y F1 macro de **0.7812**. Para la clase de desastre real obtuvo precisión de **0.8094**, *recall* de **0.6693** y F1 de **0.7327**. El ROC-AUC fue **0.8438**.

Cuadro 7: Métricas del SVM seleccionado en el conjunto de prueba.

Métrica	Valor
Accuracy	0.7919
Precisión macro	0.7959
Recall macro	0.7761
F1 macro	0.7812
Precisión, desastre real	0.8094
Recall, desastre real	0.6693
F1, desastre real	0.7327
ROC-AUC	0.8438



(a) Matriz de confusión.



(b) Curva ROC.

Figura 7: Evaluación del modelo SVM seleccionado.

La diferencia entre precisión y *recall* de la clase positiva muestra que el modelo es relativamente conservador al predecir desastre: cuando predice esa clase suele acertar, pero todavía deja sin detectar una fracción de los desastres reales. Esta observación es relevante al interpretar el desempeño y motiva evaluar información adicional al contenido TF-IDF.

8. Función de clasificación de nuevos tweets

Se implementó una función que recibe directamente un tweet sin preprocesar. La función aplica la misma limpieza utilizada durante el entrenamiento, calcula las características necesarias y devuelve la clase predicha. Cuando el modelo calibrado está disponible también devuelve la probabilidad asociada a la clase predicha. La función fue probada con ejemplos de desastres literales y expresiones figuradas, como “*I love this new phone, it’s fire!*” y “*That concert was the bomb, best night ever*”, que fueron clasificadas como no desastre.

9. Análisis de sentimiento

Para el análisis de sentimiento se utilizó **TextBlob** sobre una versión del tweet con limpieza ligera. A diferencia del texto destinado a TF-IDF, en esta etapa no se eliminó agresivamente la puntuación ni otros elementos que pueden aportar información afectiva. TextBlob devuelve una polaridad en el intervalo $[-1, 1]$ y una medida de subjetividad. En el notebook se definieron tres clases:

- **positivo** si la polaridad es mayor que 0.05;
- **negativo** si la polaridad es menor que -0.05 ;
- **neutro** en el intervalo restante.

La distribución global obtenida fue de 3,822 tweets neutros (50.83 %), 2,290 positivos (30.46 %) y 1,407 negativos (18.71 %). Por categoría, los tweets de desastre real presentaron 20.59 % negativos, 53.98 % neutros y 25.43 % positivos; los tweets que no son desastre presentaron 17.32 % negativos, 48.49 % neutros y 34.19 % positivos.

Cuadro 8: Distribución porcentual del sentimiento por categoría.

Categoría	Negativo	Neutro	Positivo
Desastre real	20.59 %	53.98 %	25.43 %
No desastre	17.32 %	48.49 %	34.19 %




Figura 8: Distribución del sentimiento por categoría.

Además de la polaridad completa del tweet, se consultó la polaridad individual de tokens para contar palabras positivas, negativas y neutras. La Tabla 9 presenta las diez de mayor frecuencia en cada grupo.

Cuadro 9: Palabras de sentimiento más frecuentes. Entre paréntesis se muestra la frecuencia.

Positivas	Negativas	Neutras
new (226)	killed (99)	like (347)
first (109)	dead (97)	not (295)
love (102)	black (68)	no (263)
full (93)	shit (56)	fire (249)
good (89)	military (52)	i'm (246)
many (78)	little (49)	get (229)
best (74)	fucking (46)	via (217)
really (71)	bad (46)	news (204)
lol (71)	bloody (45)	one (197)
right (68)	missing (43)	people (194)

10. Tweets con polaridad extrema

Los diez tweets con polaridad más negativa se muestran en la Tabla 10. Siete pertenecen a la clase de desastre real y tres a la clase de no desastre. Los diez tweets con mayor polaridad positiva se muestran en la Tabla 11; nueve pertenecen a no desastre y uno a desastre real.

Cuadro 10: Diez tweets con mayor polaridad negativa.

#	Tweet	Categoría	Polaridad
1	Horrible Accident Man Died In Wings of Airplane (29-07-2015) http://t.co/i7kZtevb2v	Desastre real	-1.00
2	#Horrible #Accident Man Died In Wings Airplane (29-07-2015) #WatchTheVideo http://t.co/p64xRVgJlk	Desastre real	-1.00
3	This is unbelievably insane. #man #airport #airplane #aircraft #aeroplane #runway #accident #freaky https://t.co/cezhq7CzLl	Desastre real	-1.00
4	Horrible Accident Man Died In Wings of Airplane (29-07-2015) http://t.co/wq3wJsgPHL	Desastre real	-1.00
5	Horrible Accident Man Died In Wings of Airplane (29-07-2015) http://t.co/TfcdRONRA6	Desastre real	-1.00
6	OMG Horrible Accident Man Died in Wings of Airplane. http://t.co/xDxDPrCPnS	Desastre real	-1.00
7	My phone looks like it was in a car ship airplane accident. Terrible	No desastre	-1.00
8	@58hif my trick is to think about nasty things	No desastre	-1.00
9	Horrific attack on wife by muslim in Italy http://t.co/nY3lloRZQb LiveLeak #News	Desastre real	-1.00
10	@envw98 @NickCoCoFree @JulieDiCaro @jdabe80 Why am I the worst person? Questioning how julie attacked him? Do you guys have no empathy?	No desastre	-1.00

Cuadro 11: Diez tweets con mayor polaridad positiva.

#	Tweet	Categoría	Polaridad
1	What a wonderful day!	No desastre	1.00
2	Ablaze for you Lord :D	No desastre	1.00
3	Building the perfect tracklist to life leave the streets ablaze	No desastre	1.00
4	'Remembering that you are going to die is the best way I know to avoid the trap of thinking you have something to lose.' – Steve Jobs	No desastre	1.00
5	Best movie you've ever seen? - Armageddon http://t.co/qoUXIgdtdbZ	No desastre	1.00
6	#NOWPLAYING Arsonist MC - So Impressed - @ARSONIST-MUSIC http://t.co/1ElreH1jLJ	No desastre	1.00
7	on town of salem i just melted ice cube bc im the arsonist :D	No desastre	1.00
8	I liked a @YouTube video http://t.co/XO2ZbPBjB3 FEMA REGION III TARGETED for BIOTERRORISM !!! NASA - JAPAN ROCKET LAUNCH with LITHIUM	Desastre real	1.00
9	the best thing at DQ is the cotton candy blizzard ??	No desastre	1.00
10	That moment when ur about to win a mini uhc and than get blown up by a creeper and get kicked for flying..... So salty rn...!!!??	No desastre	1.00

Estos extremos deben interpretarse como resultados del analizador de sentimiento y no como una nueva etiqueta de desastre. Por ejemplo, aparecen expresiones coloquiales con palabras como *ablaze*, *Armageddon* o *blown up* que reciben sentimiento positivo pese a contener vocabulario asociado a emergencias. Este contraste muestra que sentimiento y clasificación de desastre describen propiedades distintas del texto.

11. Negatividad y categoría de desastre

La variable **negativity** se definió a partir de la polaridad de TextBlob como $\max(-\text{polaridad}, 0)$, de modo que toma valores entre 0 y 1 y aumenta cuando el tweet presenta una polaridad más negativa. La media fue 0.0578 para tweets de desastre real y 0.0520 para los de no desastre, una diferencia absoluta de 0.0058.

Cuadro 12: Resumen de la variable de negatividad por categoría.

Categoría	<i>n</i>	Media	Mediana	Desv. estándar
Desastre real	3,205	0.0578	0.0000	0.1475
No desastre	4,314	0.0520	0.0000	0.1442

Para evaluar la diferencia se aplicó una prueba unilateral de Mann–Whitney U con hipótesis alternativa de que la negatividad en la clase de desastre real es mayor. Se obtuvo $U = 7,172,006$ y $p = 4.5934 \times 10^{-5}$. Con un nivel de significancia de 0.05, los datos proporcionan evidencia de una

mayor negatividad en la clase de desastre real. La magnitud de la diferencia media, sin embargo, es pequeña, por lo que su utilidad predictiva debe evaluarse directamente en el clasificador en lugar de inferirse solo a partir del valor p .




Figura 9: Comparación de negatividad entre las dos clases.

12. Efecto de incorporar la negatividad al clasificador

Para responder si la nueva variable mejora la clasificación, se comparó el mismo SVM bajo dos configuraciones: TF-IDF únicamente y TF-IDF más **negativity**. Se mantuvieron la misma partición, el mismo algoritmo y los mismos hiperparámetros para aislar el efecto de la característica adicional.

En validación cruzada sobre entrenamiento, el F1 macro pasó de 0.7752 a 0.7755. Sobre la partición de prueba utilizada para esta comparación, el F1 macro pasó de 0.7729 a 0.7751, equivalente a **+0.22 puntos porcentuales**. También aumentó ligeramente el *recall* de desastre de 0.7176 a 0.7223.

Cuadro 13: Comparación del SVM con y sin la variable de negatividad.

Modelo	Accuracy	Prec. macro	Recall macro	F1 macro	Recall desastre
SVM lineal (LinearSVC) - solo TF-IDF	0.7793	0.7751	0.7713	0.7729	0.7176
SVM lineal (LinearSVC) - TF-IDF + negatividad	0.7812	0.7770	0.7737	0.7751	0.7223




Figura 10: Comparación de métricas del modelo con y sin negatividad.

La mejora observada es real dentro de esta ejecución, pero de magnitud reducida. Por esa razón, el resultado se reporta como una mejora ligera, no como un cambio sustancial del desempeño. El notebook conserva la variable en el modelo final porque también presenta una mejora mínima en validación cruzada. Tras calibrar el modelo final con esta configuración, las métricas registradas fueron F1 macro de **0.7788**, *accuracy* de **0.7892** y ROC-AUC de **0.8419**.




Figura 11: Matriz de confusión del modelo con negatividad antes de la calibración final.

13. Reproducibilidad y productos generados

El análisis completo se conserva en `lab5_disaster_tweets.ipynb`. El proyecto incluye además `requirements.txt` con las dependencias empleadas, archivos CSV con las métricas y tablas producidas, figuras exportadas en PNG, predicciones para el archivo `test.csv` de Kaggle y el modelo serializado en `data/modelos/modelo_final_completo.joblib`. Entre los resultados utilizados directamente en este informe se encuentran:

- `data/resultados_cv_modelos.csv`;
- `data/resultados_gridsearch.csv`;
- `data/train_sentiment.csv`;
- `data/top_10_tweets_negativos.csv`;
- `data/top_10_tweets_positivos.csv`;
- `data/resumen_negatividad_categoria.csv`;
- `data/resultados_modelo_con_negatividad.csv`;
- `data/resumen_final_laboratorio5.csv`.

Esta estructura permite volver a ejecutar el análisis, verificar las métricas reportadas y reproducir las predicciones sin depender de resultados introducidos manualmente en el informe.

Referencias

- [1] D. Jurafsky y J. H. Martin, *Speech and Language Processing*. Material de referencia sobre modelos de lenguaje, n-gramas y procesamiento de lenguaje natural.
- [2] Kaggle, *Natural Language Processing with Disaster Tweets*. Conjunto de datos utilizado en el laboratorio.
- [3] Scikit-learn Developers, *Scikit-learn: Machine Learning in Python*. Documentación de `TfidfVectorizer`, `LinearSVC`, `GridSearchCV` y métricas de clasificación. <https://scikit-learn.org/>
- [4] NLTK Project, *Natural Language Toolkit*. Utilizado para recursos de preprocesamiento de lenguaje natural. <https://www.nltk.org/>
- [5] S. Loria, *TextBlob: Simplified Text Processing*. Módulo empleado para el análisis de polaridad y subjetividad. <https://textblob.readthedocs.io/>